Rapport d'analyse

Saighi Achraf et Dejmai Anis

2026-11-09

Contents

1 Statistiques Descriptives et Enseignements Tirés **1**

1.1 Analyse et prétraitement de données 1

1 Statistiques Descriptives et Enseignements Tirés

1.1 Analyse et prétraitement de données

l'etude se porte sur un jeu de données contenant **3220** enregistrements répartis de manière équilibré sur **92** sites differents, soit une étude sur 35 mois consécutifs par site, de janvier 2019 à novembre 2021, sans valeurs manquantes, sans doublons et sans consommation nulle ou négative. Chaque ligne donne, pour un site (NAME), une période de facturation (BEGIN à END) et l'énergie facturée en kWh (KWH_PERIOD).

```
##     NAME      BEGIN        END KWH_PERIOD
## 1 0007BR 01/01/2019 31/01/2019      2 500
## 2 0007BR 01/02/2019 28/02/2019      2 227
## 3 0007BR 01/03/2019 31/03/2019      2 538
## 4 0007BR 01/04/2019 30/04/2019      2 520
## 5 0007BR 01/05/2019 31/05/2019      2 581
## 6 0007BR 01/06/2019 30/06/2019      2 816
```

```
##         NAME            BEGIN             END          KWH_PERIOD
##  Length   :3220   Length   :3220   Length   :3220   Length   :3220
##  N.unique :  92   N.unique :  36   N.unique :  36   N.unique :1910
##  N.blank  :   0   N.blank  :   0   N.blank  :   0   N.blank  :   0
##  Min.nchar:   6   Min.nchar:  10   Min.nchar:  10   Min.nchar:   3
##  Max.nchar:   6   Max.nchar:  10   Max.nchar:  10   Max.nchar:   7
```

```
## date min : 01/01/2019
```

```
## date max : 30/11/2021
```

Toutefois, la colonne KWH_PERIOD est stockée sous forme textuelle avec un séparateur de milliers par espace, nécessitant un prétraitement avant l'étude, on ajoute alors la colonne KWH, qui contient la représentation numérique de la consommation.

On a également pensé à ajouter les colonnes BEGIN_DT et END_DT qui représentent les dates de debut et de fin prévu pour chaque mois, DAYS_BILLED et DAYS_EXPECTED, ça nous permettra de detecter les erreurs liées aux periodes de facturation ou du nombre de jours dans un mois donné. Ainsi que YEAR_MONTH qui nous donne le mois et l'année facturé ce qui nous permet une étude plus lisible. Et finalement, on a remarqué que les noms des stations contiennent des suffixes (ex : BR, BB...) on a pensé à ajouter la colonne SUB_PARK pour classer les stations selon leurs suffixes, ce qui nous donnera peut-être des informations utiles.

La tête de notre jeu de données et son summary s'afficherons ainsi :

```
##     NAME      BEGIN        END KWH_PERIOD  KWH   BEGIN_DT     END_DT
## 1 0007BR 01/01/2019 31/01/2019          2 500 2500 2019-01-01 2019-01-31
## 2 0007BR 01/02/2019 28/02/2019          2 227 2227 2019-02-01 2019-02-28
## 3 0007BR 01/03/2019 31/03/2019          2 538 2538 2019-03-01 2019-03-31
## 4 0007BR 01/04/2019 30/04/2019          2 520 2520 2019-04-01 2019-04-30
## 5 0007BR 01/05/2019 31/05/2019          2 581 2581 2019-05-01 2019-05-31
## 6 0007BR 01/06/2019 30/06/2019          2 816 2816 2019-06-01 2019-06-30
##   DAYS_BILLED DAYS_EXPECTED SUB_PARK YEAR_MONTH
## 1          31            31       BR    2019-01
## 2          28            28       BR    2019-02
## 3          31            31       BR    2019-03
## 4          30            30       BR    2019-04
## 5          31            31       BR    2019-05
## 6          30            30       BR    2019-06
```

```
##         NAME            BEGIN             END           KWH_PERIOD
##  Length   :3220   Length   :3220   Length   :3220   Length   :3220
##  N.unique :  92   N.unique :  36   N.unique :  36   N.unique :1910
##  N.blank  :   0   N.blank  :   0   N.blank  :   0   N.blank  :   0
##  Min.nchar:   6   Min.nchar:  10   Min.nchar:  10   Min.nchar:   3
##  Max.nchar:   6   Max.nchar:  10   Max.nchar:  10   Max.nchar:   7
##
##       KWH            BEGIN_DT             END_DT            DAYS_BILLED
##  Min.   :   126   Min.   :2019-01-01   Min.   :2019-01-31   Min.   :16.00
##  1st Qu.:  1435   1st Qu.:2019-09-01   1st Qu.:2019-09-30   1st Qu.:30.00
##  Median :  2218   Median :2020-06-01   Median :2020-06-30   Median :31.00
##  Mean   : 10624   Mean   :2020-05-31   Mean   :2020-06-30   Mean   :30.42
##  3rd Qu.:  2644   3rd Qu.:2021-03-01   3rd Qu.:2021-03-31   3rd Qu.:31.00
##  Max.   :593585   Max.   :2021-11-01   Max.   :2021-11-30   Max.   :31.00
##  DAYS_EXPECTED        SUB_PARK        YEAR_MONTH
##  Min.   :28.00   Length   :3220   Length   :3220
##  1st Qu.:30.00   N.unique :   3   N.unique :  35
##  Median :31.00   N.blank  :   0   N.blank  :   0
##  Mean   :30.43   Min.nchar:   2   Min.nchar:   7
##  3rd Qu.:31.00   Max.nchar:   2   Max.nchar:   7
##  Max.   :31.00
```